

Primer Entregable del Proyecto de Investigación

Selección de Base de Datos, Análisis Exploratorio e Implementación de Modelo Base

20 de septiembre de 2026

Objetivo del Entregable

Establecer las bases del proyecto de investigación mediante: (i) la selección de una base de datos pertinente, (ii) un análisis exploratorio de datos (EDA) riguroso y exhaustivo, y (iii) la implementación de un modelo base como referencia inicial, comparado contra una línea base trivial.

Ruta de Trabajo según el Tipo de Dataset

La Figura 1 resume el camino que debe seguir el estudiante. Todos los proyectos comparten el mismo tronco inicial (selección del dataset, reserva del conjunto de prueba, EDA general y auditoría de fuga) y luego se bifurcan según el tipo de problema y la estructura de los datos. Cada ruta indica el EDA específico, la forma de particionar los datos, el preprocesamiento, la línea base y las métricas de evaluación.

1. Base de Datos

- Definición clara del problema de investigación.
- Justificación de la selección del dataset.
- Fuente de los datos (con enlace si aplica) y licencia de uso.
- Diccionario de variables: tipo, unidad y significado.
- Estructura de los datos: unidad de observación, nivel de agregación y tipo (transversal, serie de tiempo, panel/longitudinal, con componente espacial o espacio-temporal).




Figura 1: Ruta de trabajo del estudiante según el tipo de dataset. Los números entre paréntesis remiten a las secciones de este documento. Si el dataset tiene coordenadas pero no tiempo, se sigue la ruta A o B añadiendo la sección 2.7 y una partición por bloques espaciales. Si la tarea es de clasificación con tiempo o espacio, se sigue la ruta A añadiendo las secciones 2.6 a 2.8 y la partición correspondiente.

- Tamaño de la muestra (**warning**: mínimo 20 mil observaciones). Reportar además:
 - Número de variables y relación n/p .
 - Casos por clase (clasificación) o rango de la variable objetivo (regresión).
 - Número de entidades independientes (pacientes, estaciones, clientes, etc.), pues el tamaño efectivo de la muestra puede ser menor que el número de filas.
- Calidad de datos:
 - Valores faltantes: patrón (visualización de la matriz de nulos) y mecanismo (MCAR, MAR, MNAR), con la evidencia que lo sustenta (por ejemplo, prueba de Little o comparación de distribuciones entre registros completos e incompletos).
 - Duplicados exactos y casi-duplicados.
 - Outliers (detección y tratamiento).
 - Valores imposibles o inconsistentes (rangos, unidades, categorías mal escritas).
 - Sesgos de muestreo y representatividad de la población objetivo.
- Consideraciones éticas: datos personales, anonimización y riesgos de reidentificación (en particular con coordenadas y marcas de tiempo precisas).

2. Análisis Exploratorio de Datos (EDA)

El EDA debe ser **exhaustivo**, cubriendo análisis **unidimensional**, **bidimensional** y **multivariado**. Cada resultado debe incluir **interpretación**.

Orden de trabajo. Antes de tomar cualquier decisión que se use en el modelado (imputación, transformaciones, selección de variables, umbrales de outliers), se debe reservar el conjunto de prueba. Dichas decisiones se calculan **solo con los datos de entrenamiento**. La partición debe respetar la estructura de los datos: estratificada si hay desbalance, cronológica si hay tiempo, por grupos si hay varias filas por entidad y por bloques espaciales si hay coordenadas.

2.1 Análisis de la Variable Objetivo

- Clasificación: frecuencia de cada clase, grado de desbalance y número de casos de la clase minoritaria.
- Regresión: distribución, asimetría, colas pesadas, valores extremos y necesidad de transformación (log, Box-Cox).

- Relación de la variable objetivo con cada predictora (ver 2.3).
- Comportamiento de la variable objetivo en el tiempo y en el espacio, si el dataset lo permite.
- **Interpretación:** implicaciones para la métrica de evaluación y para la estrategia de validación.

2.2 Análisis Unidimensional

Para cada variable:

- Tipo de variable y cardinalidad (categóricas).
- Estadísticos: media, mediana, desviación estándar, percentiles.
- Distribución: histogramas/densidades.
- Asimetría y curtosis.
- Pruebas de normalidad cuando sean relevantes (con cautela: en muestras grandes casi siempre rechazan).
- Outliers: boxplots e IQR.
- Variables categóricas:
 - Frecuencias.
 - Gráficos de barras.
 - Categorías raras y su tratamiento.
- **Interpretación:** comportamiento y relevancia.

2.3 Análisis Bidimensional

- Numéricas vs numéricas:
 - Scatter plots (con transparencia o hexbin si n es grande).
 - Correlación (Pearson/Spearman).
- Categóricas vs numéricas:
 - Boxplots o violin plots.
 - Pruebas de comparación entre grupos (t, ANOVA o sus alternativas no paramétricas, como Mann-Whitney o Kruskal-Wallis).

- Categóricas vs categóricas:
 - Tablas de contingencia.
 - Prueba χ^2 y V de Cramér.
- Predictoras vs variable objetivo:
 - Medidas de asociación adecuadas al tipo de variable (incluyendo información mutua para relaciones no lineales).
- Matriz de correlación:
 - Heatmap.
 - Multicolinealidad (correlaciones altas y VIF).
- Rigor estadístico:
 - Con n grande casi toda diferencia resulta significativa: reportar **tamaños de efecto** junto a los valores p .
 - Corregir por comparaciones múltiples (Bonferroni, Holm o FDR) cuando se realicen muchas pruebas.
- **Interpretación:**
 - Patrones relevantes.
 - Relaciones lineales/no lineales.
 - Selección preliminar de variables.

2.4 Análisis Multivariado

- Reducción de dimensionalidad exploratoria (PCA; UMAP o t-SNE solo como herramienta visual, no inferencial): varianza explicada y estructura de los datos.
- Outliers multivariados (distancia de Mahalanobis, Isolation Forest).
- Estructura de grupos o subpoblaciones (clustering exploratorio, si procede).
- **Interpretación:** dimensionalidad efectiva, redundancia entre variables y subpoblaciones relevantes.

2.5 Auditoría de Fuga de Datos (*Data Leakage*)

- Para cada variable, justificar que estaría **disponible en el momento de la predicción**.
- Detectar variables derivadas de la variable objetivo, identificadores y proxies del target.
- Calcular el desempeño de cada variable por separado (por ejemplo, AUC univariado): valores cercanos a 1 son señal de alerta.
- Verificar duplicados y entidades repetidas entre las particiones de entrenamiento y prueba.
- **Interpretación:** lista de variables descartadas o en observación, con su justificación.

2.6 Componente Temporal (obligatorio si el dataset tiene fecha u hora)

- Validación de la variable temporal: formato, zona horaria, frecuencia (regular o irregular), marcas de tiempo duplicadas, huecos y cobertura del periodo.
- Visualización:
 - Serie completa y agregaciones (hora, día, semana, mes).
 - Estacionalidad por ciclo (boxplots por hora, día de la semana, mes).
- Descomposición en tendencia, estacionalidad y residuo (por ejemplo, STL).
- Estacionariedad: medias y varianzas móviles, pruebas ADF y KPSS.
- Dependencia temporal: ACF, PACF y correlación cruzada con rezagos entre predictoras y objetivo.
- Cambios de régimen, puntos de cambio, eventos y efectos de calendario (feriados, temporadas).
- Deriva temporal: comparar la distribución de las variables y del objetivo entre periodos (*covariate shift* y *concept drift*).
- Si hay varias entidades (panel): series por entidad y heterogeneidad entre ellas.
- **Consecuencias para el modelado:**
 - La partición train/test es **cronológica**, nunca aleatoria; la validación cruzada usa esquemas de ventana creciente o deslizante (por ejemplo, `TimeSeriesSplit`), con un intervalo de separación (*gap*) si hay dependencia de corto plazo.
 - Rezagos y ventanas móviles se construyen **solo con información pasada**.
- **Interpretación:** tendencia, ciclos, estabilidad del proceso y riesgo de deriva.

2.7 Componente Espacial (obligatorio si el dataset tiene latitud/longitud)

- Validación de coordenadas:
 - Sistema de referencia (CRS), por ejemplo EPSG:4326.
 - Rangos válidos: latitud en $[-90^\circ, 90^\circ]$ y longitud en $[-180^\circ, 180^\circ]$.
 - Latitud y longitud invertidas, coordenadas nulas o $(0, 0)$, puntos fuera del área de estudio, precisión y duplicados espaciales.
- Visualización:
 - Mapa de puntos sobre mapa base.
 - Mapas de densidad (KDE o hexbin) y coropletras por unidad geográfica.
 - Mapas de la variable objetivo y de las variables más relevantes.
- Patrón de puntos y cobertura: agrupamiento o dispersión (índice del vecino más cercano, función K de Ripley), detección de *clusters* espaciales (DBSCAN/HDBSCAN con distancia haversine) y zonas sin cobertura (sesgo de muestreo espacial).
- Autocorrelación espacial:
 - Definir la matriz de pesos espaciales (k vecinos, banda de distancia o contigüidad) y justificar la elección.
 - I de Moran global, indicadores locales (LISA) y *hotspots* (Getis-Ord G_i^*).
 - Semivariograma cuando los datos son puntuales y continuos.
- Heterogeneidad espacial: diferencias entre regiones y relaciones que cambian según la ubicación.
- Distancias: usar distancia haversine o un CRS proyectado; no aplicar distancia euclidiana sobre grados.
- Efecto de la escala y de la unidad de agregación (problema de la unidad de área modificable, MAUP).
- Ingeniería de características espaciales: distancia a puntos de interés, celdas (H3, geohash), variables de vecindad (rezago espacial). Justificar el uso de latitud y longitud crudas como predictoras.
- **Consecuencias para el modelado:** como puntos cercanos se parecen, la validación aleatoria es optimista. Usar validación por bloques espaciales (GroupKFold por celdas o *clusters*), con zona de separación (*buffer*) entre entrenamiento y prueba cuando sea posible.

- **Interpretación:** patrones geográficos, dependencia espacial y su implicación para la generalización a zonas nuevas.

2.8 Componente Espacio-Temporal (si el dataset tiene coordenadas y tiempo)

- Mapas por periodo (paneles por mes, estación u hora) y animaciones cuando aporten claridad.
- Series de tiempo por celda o zona, y comparación entre zonas.
- Interacción espacio-tiempo: ¿los patrones espaciales cambian con el tiempo? ¿Se desplazan los *hotspots*? (por ejemplo, *hotspots* emergentes o prueba de Knox).
- Autocorrelación espacio-temporal.
- **Consecuencias para el modelado:** definir explícitamente si el objetivo es predecir en el futuro, en zonas nuevas o en ambos, y diseñar la partición en consecuencia (bloques espacio-temporales). Reportar el resultado de cada esquema por separado.
- **Interpretación:** dinámica espacio-temporal del fenómeno y riesgos de fuga por vecindad en espacio y tiempo.

2.9 Preprocesamiento

- Todo el preprocesamiento se implementa dentro de un **Pipeline** y se ajusta solo con el conjunto de entrenamiento.
- Imputación de datos faltantes (justificada por el mecanismo identificado).
- Transformaciones (log, escalamiento).
- Codificación categórica.
- Tratamiento de outliers.
- Ingeniería de características derivada de los hallazgos del EDA, por ejemplo:
 - Temporales: componentes cíclicos (seno y coseno), rezagos, ventanas móviles, indicadores de calendario.
 - Espaciales: distancias, celdas, variables de vecindad.
- Documentar cada decisión y el hallazgo del EDA que la motiva.

3. Modelo Base

- Regresión logística o SVR lineal.

Requisitos:

- Definición de variable objetivo.
- **Línea base trivial** como referencia mínima:
 - Clasificación o regresión general: `DummyClassifier` o `DummyRegressor`.
 - Series de tiempo: persistencia (último valor) o ingenuo estacional.
 - Datos espaciales: media global o media por zona.
- División train/test acorde con la estructura de los datos (estratificada, cronológica, por grupos o por bloques espaciales), definida antes de cualquier preprocesamiento.
- Entrenamiento mediante `Pipeline`, con validación cruzada del mismo tipo que la partición elegida.
- Evaluación:
 - Clasificación: accuracy, precision, recall, F1, AUC, matriz de confusión y curva ROC. En caso de desbalance, curva precisión-recall y calibración.
 - Regresión: RMSE, MAPE, R^2 y análisis de residuos (normalidad, heterocedasticidad).
 - Intervalos de confianza (por ejemplo, bootstrap) para las métricas principales.
 - Comparación explícita con la línea base trivial.
- Diagnóstico de residuos según la estructura: autocorrelación temporal (ACF de residuos) y autocorrelación espacial (I de Moran de residuos). Residuos con dependencia indican información estructural sin capturar.
- Curva de aprendizaje para evaluar si el tamaño de muestra es suficiente y si hay sobreajuste.
- Interpretación de coeficientes y de las métricas.

Nota crítica

Si el modelo presenta un desempeño alto (accuracy o R^2 entre 80 %–90 % o superior):

- Verificar *data leakage* (incluida la fuga temporal y espacial descrita en las secciones 2.5 a 2.8).
- Comparar con la línea base trivial: con clases desbalanceadas, un accuracy alto puede ser solo la proporción de la clase mayoritaria.
- Si hay tiempo o espacio, comprobar que la validación respeta esa estructura: la autocorrelación puede inflar el desempeño de forma artificial.
- Revisar complejidad del dataset.
- Evaluar si el problema es trivial para el curso de Machine Learning.
- Considerar un dataset más desafiante.

Entregables

- Informe **SI O SI** en Jupyter Book (ver https://youtu.be/m_wCMg2EmdQ?si=ZKQuLk0o1KT07uCZ).
- Base de datos o enlace.
- Archivo de dependencias (`requirements.txt` o `environment.yml`) y semillas aleatorias fijadas.

Evaluación

Criterio	Peso
Base de datos	10 %
EDA (rigor y exhaustividad)	60 %
Modelo base	30 %

Los componentes temporal, espacial y espacio-temporal (secciones 2.6 a 2.8) se evalúan dentro del criterio de EDA cuando el dataset los incluye.

Buenas Prácticas

- Usar datasets relevantes.

- No debe existir *overfitting* ni *data leakage* (ver Sección 9. Evaluación de modelos y Sección 10. Pipelines.).
- Reservar el conjunto de prueba antes de tomar decisiones basadas en los datos y no usarlo durante el ajuste de hiperparámetros.
- Documentar decisiones adecuadamente en la entrega.
- Garantizar reproducibilidad (semillas, versiones de librerías, código ejecutable de principio a fin).
- El EDA debe guiar el modelado: cada decisión de preprocesamiento y validación debe poder rastrearse a un hallazgo del EDA.
- Reportar incertidumbre (intervalos de confianza) y no solo valores puntuales.
- Declarar limitaciones: sesgos de muestreo, representatividad y riesgos éticos.

Observación Final

Un EDA sólido y bien interpretado es determinante para el éxito del proyecto.